


第1回

AI基礎


世間一般のAIのイメージ

一番よくある画像分類・判定
画像から物体を認識して領域を切り出す



画像判定系の一番の応用といえば……

自動運転はこれをリアルタイムで実施




AIってバズワード？

10年前はクラウドがバズワード

今はAIが一番のバズワード

しかし、クラウドはすっかり根付いてもう欠かせなくなった
AIもバズワードになりつつも、この先欠かせなくなる？



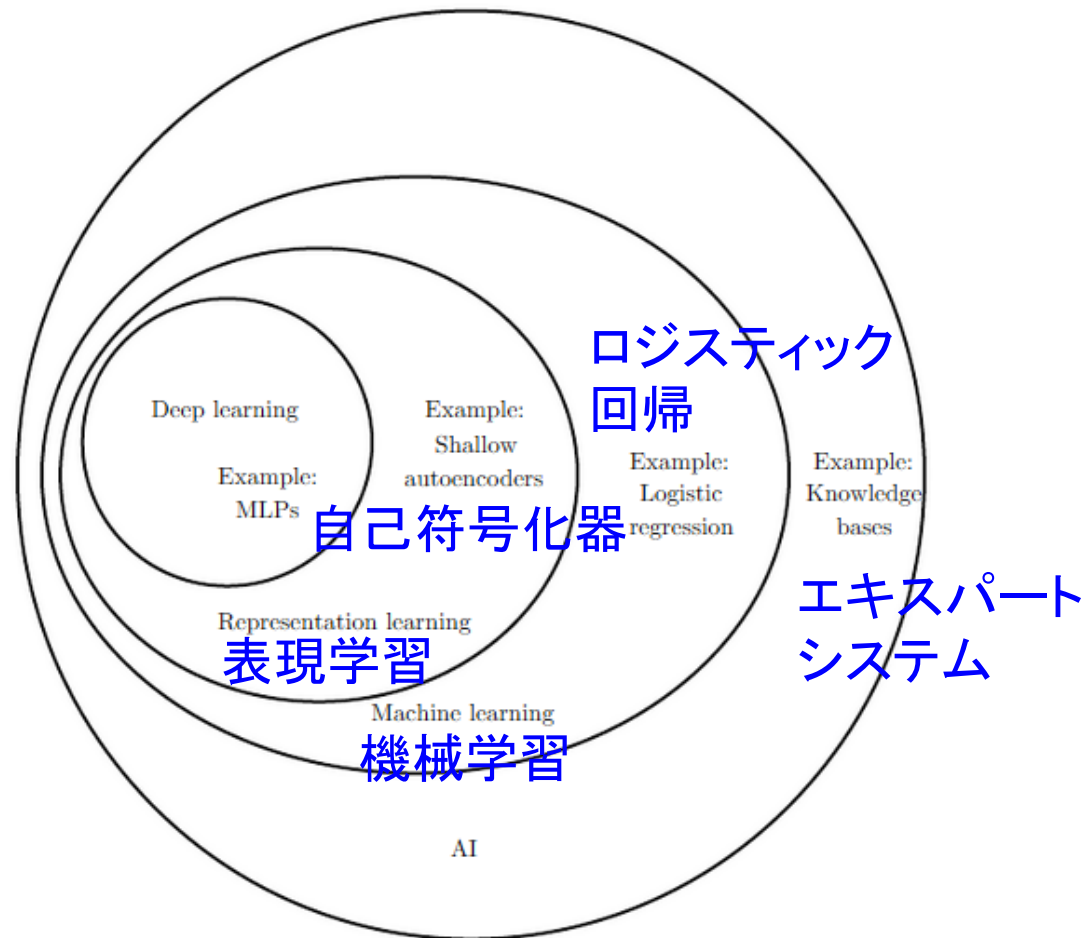
今日のテーマ

午前 大阪から：AIと機械学習と深層学習(Deep Learning)の区別をつける
AIは怖くない

午後 東京から：ビジネスへの応用(1)
まずざっくりとAIをどのようにビジネスへ活かせるか考える

AIの歴史と概念（再掲）

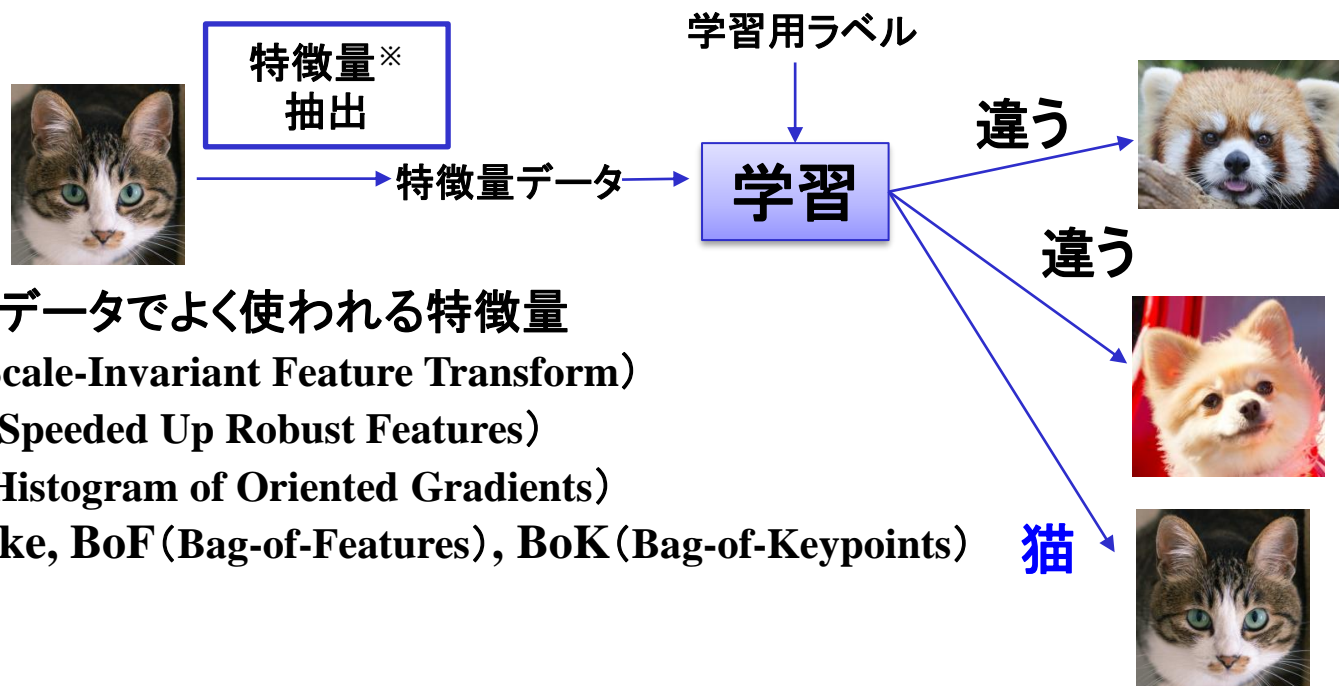
Goodfellow(Apple)
による概念図



Ian Goodfellow, Yoshua Bengio and Aaron Courville, "Deep Learning", The MIT Press, 2016

従来の機械学習

例) 画像の物体認識 (OpenCVなど)



※画像データでよく使われる特数量

SIFT (Scale-Invariant Feature Transform)

SURF (Speeded Up Robust Features)

HOG (Histogram of Oriented Gradients)

Haar-like, BoF (Bag-of-Features), BoK (Bag-of-Keypoints)

etc.

機械学習では、認識すべき対象の着目点(=入力データ)は人間が考える


例) OpenCVによる画像識別

ハール(Haar)特徴量にもとづくCascade 識別器を使用

P. Viola (2001)によるオブジェクト検出の研究とR. Lienhart (2002)による改良がベースになっている

白と黒で構成される矩形を画像に適用し、対象画像の特徴量を作成する
例えば顔画像は、目の領域の画素は周辺よりも暗い、口の領域の画素が周辺より明るい、などの特徴が得られる

顔、目、正面、上半身、下半身、笑顔、などの識別器がOpenCVで利用できる

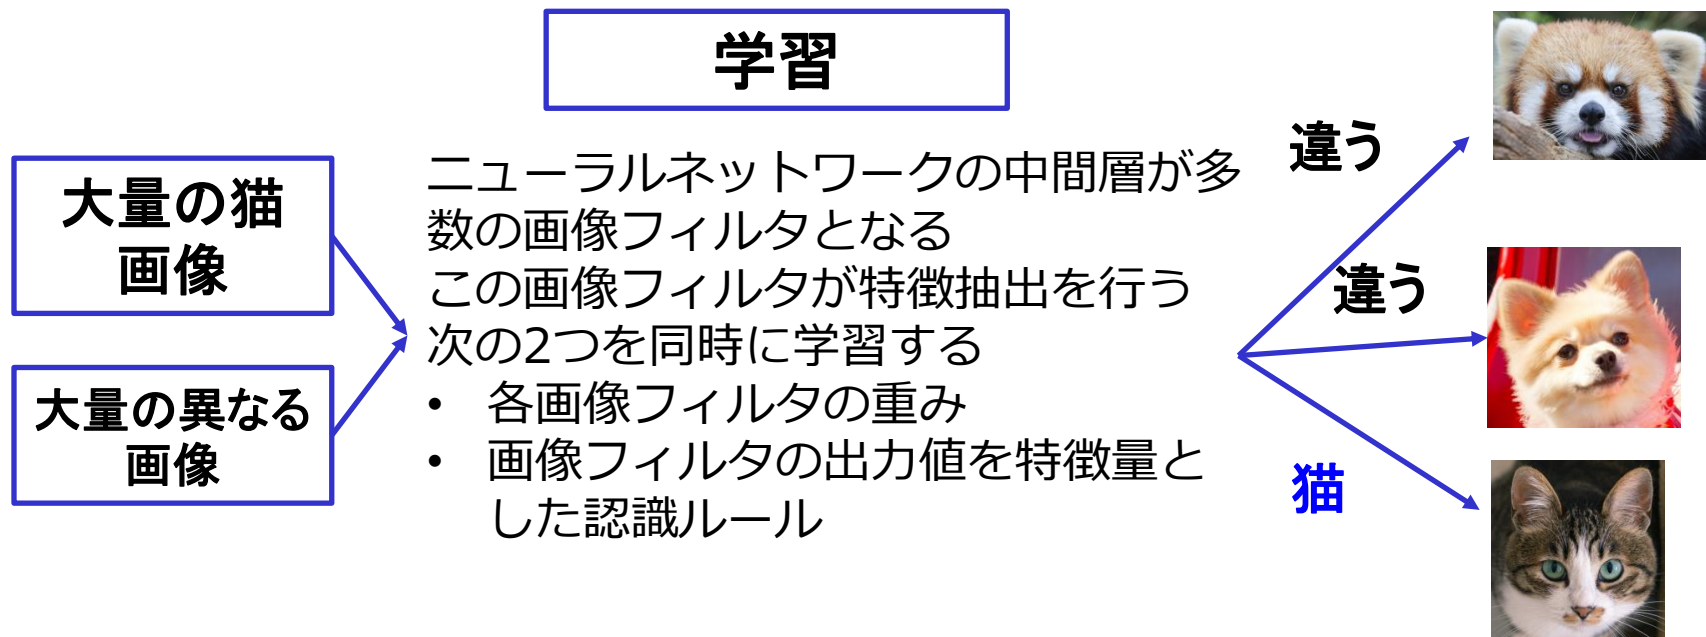


Sample face detection from, Paul Viola and Michael J. Jones, "Rapid Object Detection using a Boosted Cascade of Simple Features", IEEE CVPR, 2001.

Deep Learningの学習


例) 画像の物体認識

大量の正解画像と不正解画像（の画素値）をニューラルネットワークの入力とし、特徴と認識ルールを自動的に学習させる



従来のニューラルネットワーク

処理能力の限界から、入力層、中間層、出力層の3層構造が多く精度の問題があった




精度の問題

Deep Learning (深層学習)

中間層を多層化することで精度の問題を解決

ただし、GPUを使用してもやはり処理時間はそれなりにかかってしまう



中間層を多層化

従来手法と深層学習は何が違うのか

従来手法

人間が、どのような特徴量に着目するか、あらかじめ特徴を定義する

深層学習

コンピュータによって、特徴量を自動的に抽出する


ただし、学習のためのネットワークは人間が用意する

具体例紹介

きのこのこの山とたけのこのこの里の分類 (Interface 2017年8月号より)

従来の機械学習 (SVM)


- 入力対象の何を抽出し、どうやって解析するかを人間が考える
- 1. きのこの山は柄の部分細かいので白い部分が多そう
- 2. きのこの山は傘の部分に凹凸が多そう
- 画像取得→2値化 (チョコの部分抽出)
- 1. バウンディングボックス内の白と黒の面積比の計算
- 2. 黒い部分の頂点を検出し頂点数を求める
- 分類対象を1. と2. の数値データで表している



(Interface 2017年8月号 p.33)

Deep Learning

- 取得した画像を入力データとする
 - 画像の画素値が入力データ



(Interface 2017年8月号 p.33)

機械学習とは

Arthur Samuel (1959)

"Field of study that gives computers the ability to learn without being explicitly programmed"

明示的にプログラムしなくても学習する能力をコンピュータに与える研究分野



Photo by https://en.wikipedia.org/wiki/Arthur_Samuel

機械学習の例

k-近傍法（教師あり）

決定木（教師あり）

ランダムフォレスト（教師あり）

自己組織化マップ（教師なし）

サポートベクターマシン（教師あり）

ニューラルネットワーク（教師あり）

遺伝的アルゴリズム

ベイジアンネットワーク

人工知能とは

人工知能のFAQ（人工知能学会のサイトより抜粋）

Q. 人工知能とは何でしょうか？

- A. 知的な機械、特に、知的なコンピュータプログラムを作る科学と技術です。人の知能を理解するためにコンピュータを使うことと関係がありますが、自然界の生物が行っている知的手段だけに研究対象を限定することはありません。

Q. では、知能とは何でしょうか？

- A. 知能とは、実際の目標を達成する能力の計算的な部分です。人間、動物、そして機械には、種類や水準がさまざまな知能があります。

Q. AIは人の知能をまねようとしているのではないのですか？

- A. ときにはそうしますが、いつもというわけではありません。あるときは、機械に問題を解決させることについて、他人や自分自身がどうするかを調べます。一方、AIのほとんどの研究は、人間や動物について研究するよりも、知的に解決しなければならない問題そのものについて研究しています。AI研究者は、人間がやらないような方法や、人間ができるよりも多くの計算を伴う方法を用いることもできます。

AIは何の略ですか？

Artificial Intelligence :人工的な 知性

教師あり学習

- 人間（教師）があらかじめ用意したデータとパターンを学習し、ここから新しいデータに対して何らかの結果を出力する

教師なし学習

- 与えられたデータやパターンから、何らかの規則性をAI自らが発見し、見いだす

強化学習

- どのような行動を取れば最大限の利益が得られるかを学習する（囲碁やチェスなど）

ニューラルネットワークとは


シナプスの結合によりネットワークを形成した人工ニューロン（ノード）が、学習によってシナプスの結合強度を変化させ、問題解決能力を持つようなモデル（Wikipediaより）

教師あり学習、教師なし学習の両方がある

単純パーセプトロン

入力層と出力層の2層のみの
ニューラルネットワーク

入力 X に対して重みとバイアスを用いた
計算により得られた値と教師データ Y
の誤差を計算し、誤差が小さくなる
ように重みとバイアスを更新して
学習する




単純パーセプトロンの例

ニューロン

情報処理と情報伝達に特化した神経組織

電気信号を樹状突起から軸索末端に伝達する


昆虫で10万、人間にはおよそ1000億のニューロンが存在している



髄鞘をもつ神経細胞の構造図(Wikipedia 神経細胞 より)

形式ニューロン


1943年に発表された人工ニューロン。マカロックとピッツによって発表されたので、マカロック・ピッツモデルとも呼ばれる
ニューロンに対する入力を足し合わせ、ある閾値を超えると発火する



Warren S. McCulloch; Walter Pitts. "A logical calculus of the ideas immanent in nervous activity". *The bulletin of mathematical biophysics* (Kluwer Academic Publishers) 5 (4): pp.115-133, 1943.

ニューロンの発火

設定された閾値を超えて、初めてニューロンは値を出力する
閾値はコップのようなもの。コップの容量内なら水を入れてもこぼれないが、容量を超えると水があふれる



AIの歴史

1960年代：最初期のAI。推論・探索の研究が盛んに行われたが、まったく実用的ではなく、急速にブームが収束

1980-90年代：エキスパートシステム、ファジー

専門分野の知識を取り込み、推論を行うことでその分野のエキスパートのように振る舞うシステム

If-Thenルール：条件を定義し、条件を満たせばその条件における判断を下す

2010年代：Deep Learning

図表4-2-1-5 人工知能 (AI) の歴史

	人工知能の置かれた状況	主な技術等	人工知能に関する出来事
1950年代			チューリングテストの提唱 (1950年)
1960年代	第一次人工知能ブーム (探索と推論)	<ul style="list-style-type: none"> 探索、推論 自然言語処理 ニューラルネットワーク 遺伝的アルゴリズム 	ダートマス会議にて「人工知能」という言葉が登場 (1956年) ニューラルネットワークのパーセプトロン開発 (1958年) 人工対話システムELIZA開発 (1964年)
1970年代	冬の時代	<ul style="list-style-type: none"> エキスパートシステム 	初のエキスパートシステムMYCIN開発 (1972年) MYCINの知識表現と推論を一般化したEMYCIN開発 (1979年)
1980年代	第二次人工知能ブーム (知識表現)	<ul style="list-style-type: none"> 知識ベース 音声認識 	第五世代コンピュータプロジェクト (1982～92年) 知識記述のサイクプロジェクト開始 (1984年) 誤差逆伝播法の発表 (1986年)
1990年代	冬の時代	<ul style="list-style-type: none"> データマイニング オントロジー 	
2000年代	第三次人工知能ブーム (機械学習)	<ul style="list-style-type: none"> 統計的自然言語処理 	ディープラーニングの提唱 (2006年)
2010年代		<ul style="list-style-type: none"> ディープラーニング 	ディープラーニング技術を画像認識コンテストに適用 (2012年)

(出典) 総務省 「ICTの進化が雇用と働き方に及ぼす影響に関する調査研究」(平成28年)

ELIZA

最初期のAI。基本的にルールベース

ELIZA自身は精神科医という立場を取り、人間と対話する

今の技術からすると稚拙だが、当時はブームに。一部のユーザーはワイゼンバウムがその仕組みを説明しても納得せず、ELIZAの応答を真剣に受け止めた
日本でも類したものに、人工無脳、チャットボットがある

例)

人間: I have a terrible headache.

ELIZA: Maybe you should consult a doctor of medicine, I am psychiatrist.

画像をパターンで扱う


ヒューベル・ウィーゼルの階層仮説（1958年）

猫の視覚野にある線分を見せた時に反応する細胞があることを発見

さらに、単純型細胞(a)と複雑型細胞(b)の2種類に大別

単純型：パターン（線分）がある領域内に存在するときのみ反応

複雑型：パターン（線分）は領域からずれても反応




「これならわかる深層学習入門」 瀧雅人, 講談社 より

パターンの抽出

単純型細胞(a)が反応する部分を1つのニューロンに集める (c)

これを繰り返すことで、単純型細胞を複雑型細胞として束ねることができる
この考え方を元にして、1979年に福島(NHK)が単純型と複雑型を交互に重ねた多層ネットワーク、ネオコグニトロン^{*}を提唱


さらにこれを発展させ、ヤン・ルカンが1989年に5層、1998年に8層のCNNの構築・学習に成功している(LeNet)しかしこの後しばらくニューラルネットワークは冬の時代へ



^{*}福島邦彦、位置ずれに影響されないパターン認識機構の神経回路のモデル --- ネオコグニトロン
---、1979年、電子通信学会論文誌A, vol. J62-A, no. 10, pp. 658-665

AIの歴史と概念（再掲）

Goodfellow(Apple)
による概念図




Ian Goodfellow, Yoshua Bengio and Aaron Courville, "Deep Learning", The MIT Press, 2016

書籍: DEEP LEARNING

英語版800ページ、日本語版600ページというボリューム

英語版はWebでも公開されている: <http://www.deeplearningbook.org/>



ちょっとブレイク

今後の受講中サポートについて検討中です

リモート講師からのサポートがまだ決まっていません

Slack, MS Teams, Cisco Teams, Zoomブレイクアウトルームなど検討中ですが、皆さんがやりやすいものはありますか？

(MS Teamsは会社で使っているので使いやすい or 紛らわしいからちょっと……など)



流行したきっかけ: 1




G.H.ヒントン(Toronto Univ., Google)の2006年の論文
“Reducing the Dimensionality of Data with Neural Networks”, G. E. Hinton, R. R. Salakhutdinov, Science 28 Jul, Vol. 313, Issue 5786, pp. 50111-507,(2006)

要旨：小さな中心層を持つ多層ニューラルネットワークを訓練することによって高次元の入力ベクトルを再構成し、高次元のデータを低次元の符号に変換することができる。このような“Auto Encoder” ネットワークでは、グラディエント降下を使用してウェイトを微調整できるが、これは初期の重みが適切なソリューションに近い場合にのみ効果がある。本論文では、データの次元性を低減するツールとして主成分分析よりもはるかに良く働く低次元符号をDeep Auto Encoder ネットワークが学習することを可能にする重みを初期化する効果的な方法を述べる。

流行したきっかけ: 2

物体認識率コンテストである IMAGENET Large Scale Visual Recognition Challenge 2012 (ILSVRC2012)において、G.H.ヒントンのチームがDeep Learning手法で従来26%のエラー率を15%まで改善させた



LeNetを発展させたCNN

AlexNet: 5つの畳み込み層、3つの全結合層、65万ニューロン

ILSVRC2012 結果

1000万枚の画像で学習しテスト用に用意された15万枚画像のエラー率を競う
 HintonらのSuperVisionのエラー率是他チームを圧倒
 他チームは従来の特徴量抽出技術の延長
 ディープラーニング手法はSuperVisionのみ

チーム名	エラー率 (%)	備考
SuperVision	15, 16	Hintonら
ISI	26, 27	牛久ら東大チーム
OXFORD_VGG	27	Simonyanら Oxford Univ.
University of Amsterdam	29	アムステルダム大学
XRCE/INRIA	33	イエーナ大学

<http://www.image-net.org/challenges/LSVRC/2012/results.html>

ILSVRCでは1000カテゴリの画像分類を行う

<http://image-net.org/challenges/LSVRC/2012/browse-synsets>

その後の発展: GoogLeNet, VGG16

ILSVRC2014で1位がGoogLeNet, 2位がVGG16

GoogLeNet: Googleによる22層モデル。Inceptionモデルとも呼ばれ、Googleが開発しているTensorflowでは、最新版のInception-v3がソースレベルで公開されている。（ネットワークは優秀だが複雑）

VGG16: Oxford Univ.によるAlexNetの拡張系。16層によるCNNで、設計がシンプルなので2位に終わったがよく使われるように。19層使用するVGG19もある

人間の認識率を超える

ILSVRC2015では人間の画像認識エラー率 4%を超える、3.5%の結果を
Microsoft Research Asiaのチームが実現

ここでは、ResNetと呼ばれる152層のニューラルネットワークが使用された
前年のILSVRC2014で使用された主要ネットワーク VGGは19層、GoogleNet
は22層なので、前年よりも7倍近い規模


多層にすればある程度は性能が上がるが、多くしすぎると逆に誤差が増加し
たり、逆誤差伝搬の問題もあり、様々な工夫がなされている

Deep Residual Learning MSRA @ ILSVRC & COCO 2015 competitions
http://kaiminghe.com/ilsvrc15/ilsvrc2015_deep_residual_learning_kaiminghe.pdf

流行したきっかけ: 3

Googleによる猫の「認識」(2012年)

YouTubeにアップロードされている動画から、ランダム抽出した200x200ピクセルサイズの画像を1000万枚用意し、Deep Learningに入力した
3%前後の画像に人間の顔が含まれており、猫が含まれる画像も多数
Googleクラウドの1,000台を使用して3日間計算した




9層のネットワーク構成

人間の認識

Googleの研究では、人間の顔、背中、猫に強く反応するニューロンの選択に成功




ニューロンが反応した顔写真群



ニューロンによって生成された
人間の顔の特徴

猫の認識

本物の猫



ニューロンが反応した猫写真群

ニューロンによって生成された
猫の顔の特徴

<https://googleblog.blogspot.com/2012/06/using-large-scale-brain-simulations-for.html>

人工知能の世間的な分類

レベル1：単純な制御プログラム

- マーケティング的に「人工知能」を名乗っているだけ

レベル2：古典的な人工知能

- 推論、探索、知識ベースなどにより、組み合わせが極端に多い入力と出力を関係付ける方法を定義する

レベル3：機械学習を取り入れた人工知能

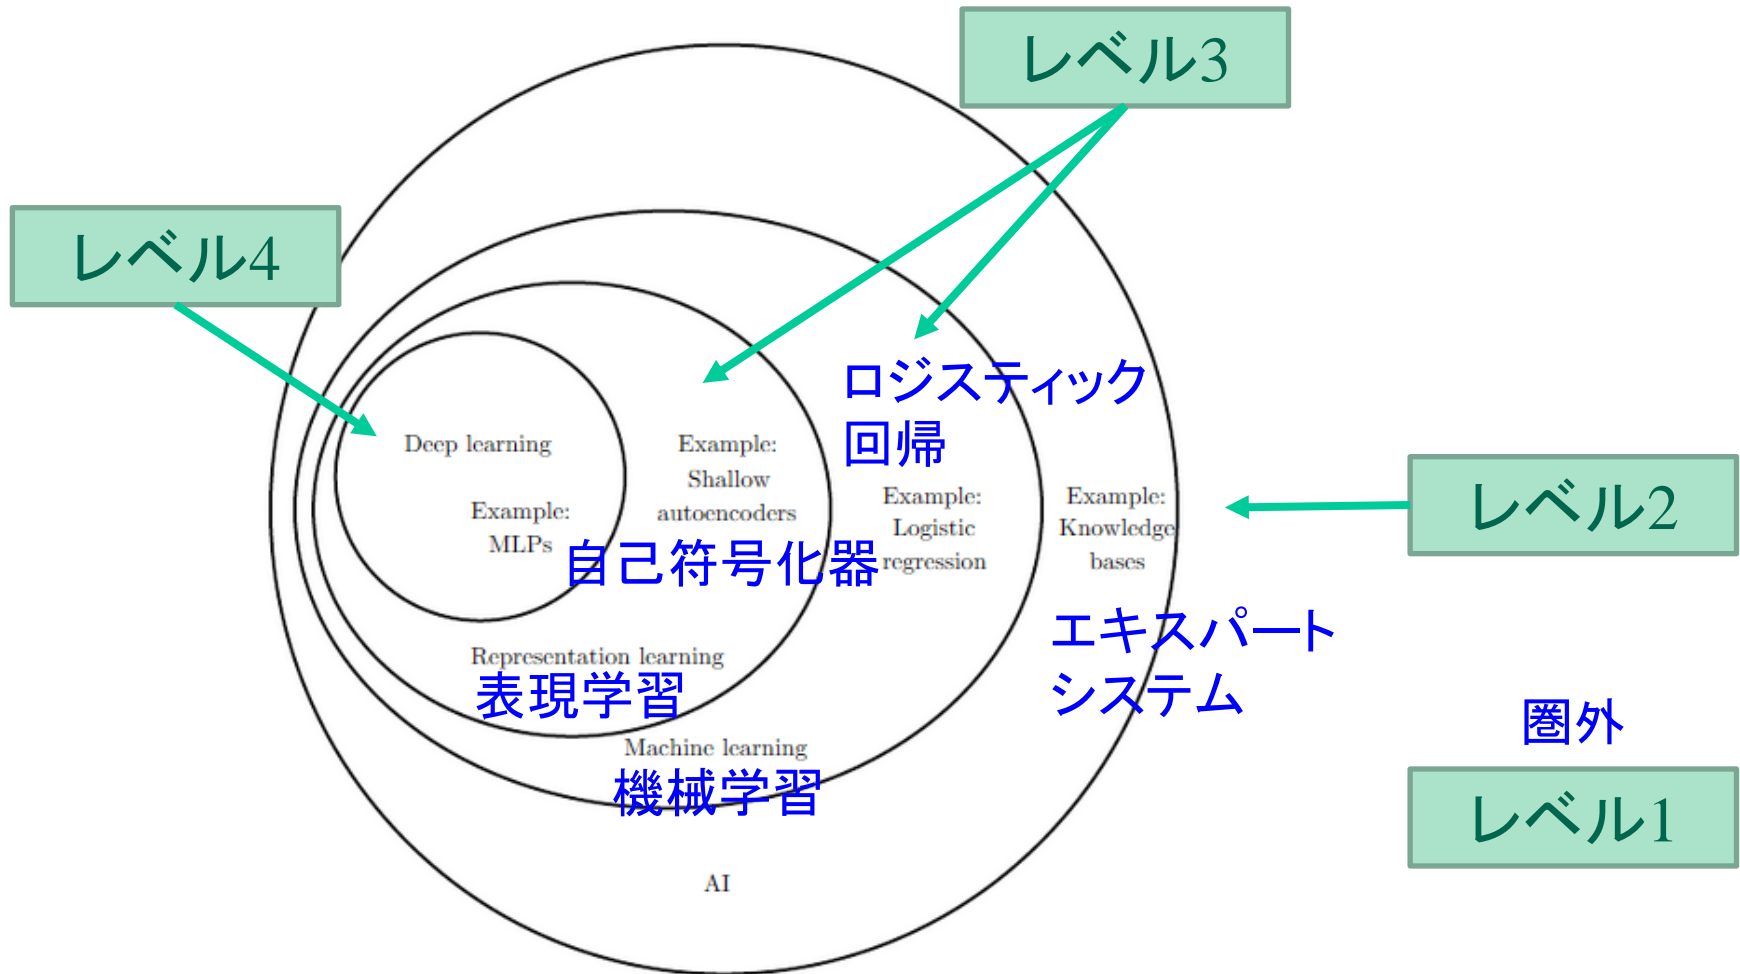
- サンプルやデータをもとに入力と出力の関係であるルールや知識を自ら学習する
- 入力は、目的に応じて入力対象の特徴をあらわすもの（特徴量）である必要がある

レベル4：ディープラーニングを取り入れた人工知能

- 特徴量自体を学習する機械学習

（松尾豊、「人工知能は人間を超えるか」より）

Goodfellowの図と対応



Ian Goodfellow, Yoshua Bengio and Aaron Courville, "Deep Learning", The MIT Press, 2016

弱い人工知能（AI）と強い人工知能（AI）

ジョン・サール（アメリカの哲学者）の造語

□ 弱い人工知能

- 人間の全認知能力を必要としない程度の問題解決や推論を行うソフトウェアの実装や研究
- チェスや囲碁など限定された範囲の問題について、一見知的に見える問題解決ができるもの

□ 強い人工知能

- 人間の知能に迫るようになるか、人間の仕事をこなせるようになるか、幅広い知識と何らかの自意識を持つもの

□ 汎用人工知能（≡強い人工知能）AGI: Artificial General Intelligence

- 人間レベルの知能を実現するもの
- 限定された問題を解決する特定型人工知能ではなく、一般的な知能を実現するもの

人工知能の利用動向

- 人工知能の効果を最大化するためには、質の高い学習用データを基に付加価値を生み出す学習済みモデルを生成することが重要
- 学習済みモデルを初期状態とし再利用することで、比較的少数の学習データから優れた性能を持つ派生データを得ることができる
- 画像認識や音声認識の領域ではすでに実用性の高い技術として応用が進められている
 - 自動走行における車外走行環境認識、医用画像からの疾病等の診断支援など
 - 家庭や自動車内での音声対話や音声アシスタント、工場での異常音検知など

(AI白書2017より)

今後の展望

海外では検索サービスやSNSなどのインターネット空間での活動から得られるデータに対して適用を進めている

海外企業がすでに圧倒的なシェアを持つインターネット空間を中心とした人工知能利用に、今後対抗することは容易ではない

先行する企業はAIの機能を組み込んだ機械やロボットを普及させることで実空間における消費者との接点も押さえつつある



健康情報、自動車の走行データ、工場の稼働データなど、個人や企業の実世界における活動から得られる実空間データへの適用は今後の競争課題

(AI白書2017より)

AIの課題(フレーム問題)

1969年にマッカーシーとヘイズが指摘した人工知能研究の最大の難問であり、今からしようとしていることに関係のある事柄だけを選び出すことが、実は非常に難しいという問題


AI搭載のロボットは、人間の代わりに危険な作業を行う。爆弾が仕掛けられている部屋から、美術品を取り出してくる作業において、美術品の入った台車を押して作業をしていたが、爆弾が台車に仕掛けられていたので爆発に巻き込まれてしまった。そこで、改良型ロボットが作られ、再度部屋に向かった。しかし、美術品を運び出すには台車を動かせばよいと思いついたあと、台車を動かしたときの影響を、天井は落ちてこないか、部屋の壁の色は変わらないか、電気は消えないか……などと考えているうちに爆弾が作動してしまった



J.McCarthy and P.J.Hayes Some philosophical problems from the standpoint of artificial intelligence, Machine Intelligence, vol.4, pp.463-502 (1969) 画像はAI学会Webサイトより

AIの課題(シンボルグラウンディング問題)

記号システム内のシンボルがどのようにして実世界の意味と結びつけられるかという問題。記号接地問題とも呼ぶ。ハルナッドが提唱



猫

人間は、猫の画像と、猫という概念・意味を理解している
AIがこれを理解するには、目が2つ、耳が頭の上に……などの猫の特徴を細かく画像で理解するしかない。しかし、りんごと青りんごや、シマウマと馬などがそれぞれ近い種類であることは、単なる画像認識ではわからない

Harnad, S.: "The Symbol Grounding Problem", Physica D 42: pp.335-346, 1990.

AIの実例：自動運転

国土交通省による自動運転のレベル

レベル1：運転支援 自動ブレーキ、車線検知など

レベル2：特定条件下での自動運転機能 レベル1の組み合わせなど

レベル3：条件付自動運転 システムが全ての運転タスクを実施するが、システムの介入要求等に対してドライバーが適切に対応することが必要

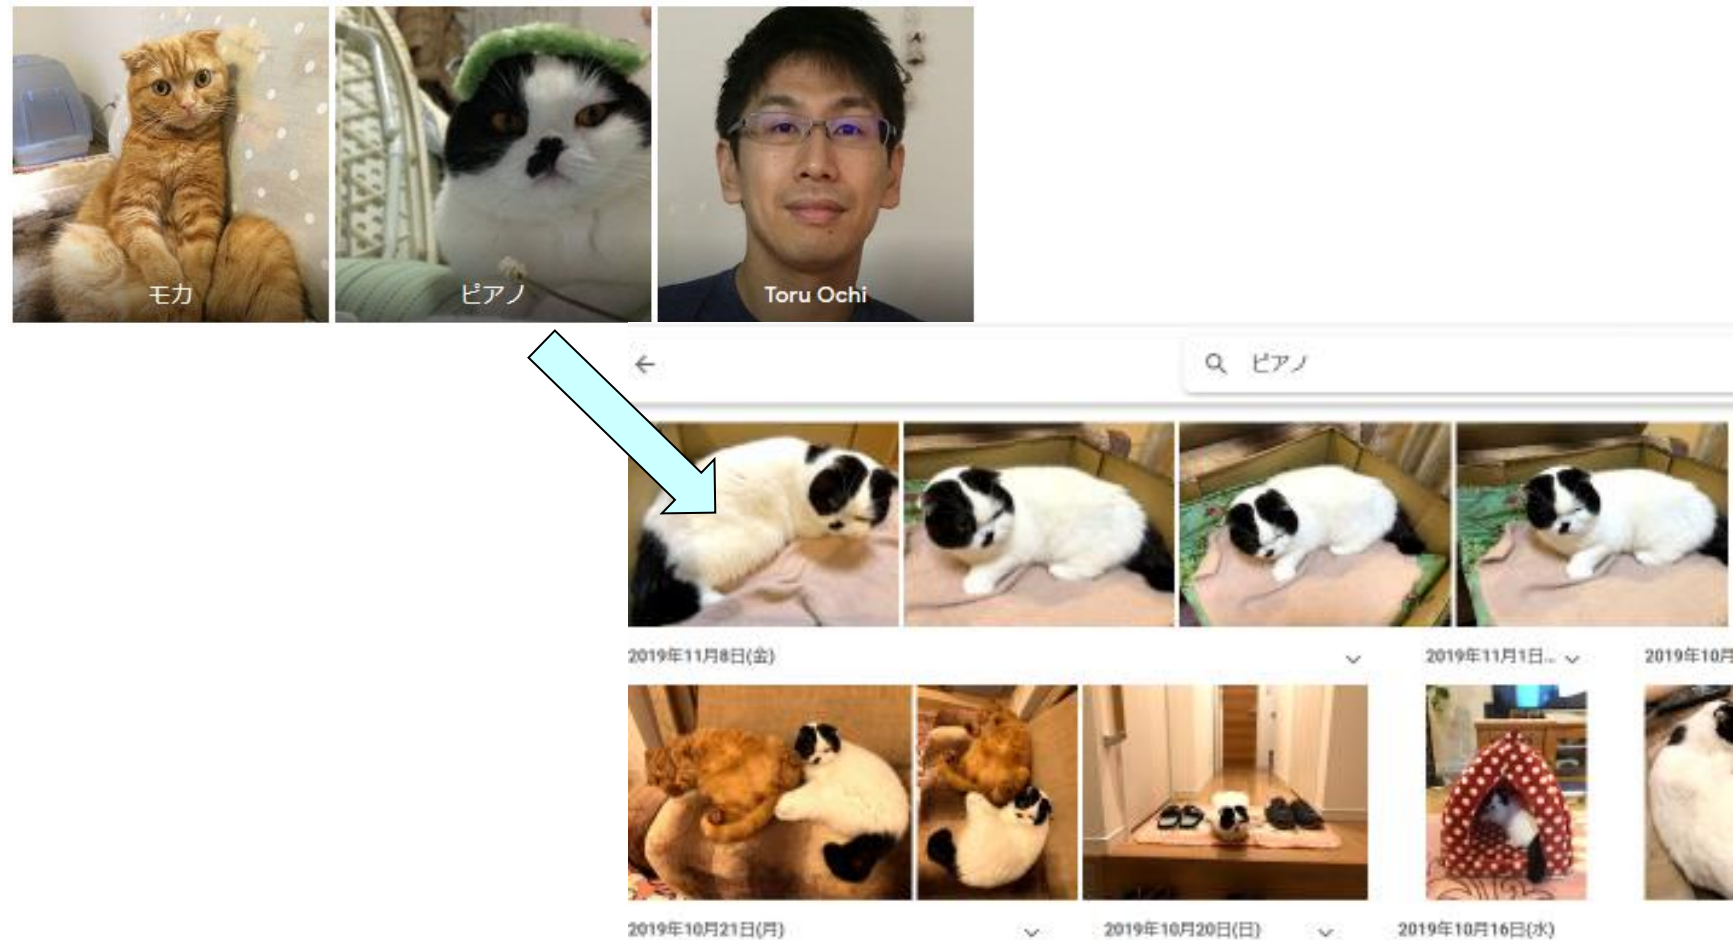
レベル4：特定条件下における完全自動運転 特定条件下においてシステムが全ての運転タスクを実施

レベル5：システムによる完全自動運転

現在、米テスラがレベル3の自動運転を提供。ただし事故も報告されている

実例 : Google Photo

人物や動物を登録すると、自動で抽出してくれる



パンの自動選別

株式会社ブレイン によるトレイ上のパン自動選別システムBakeryScan
手法としては従来型の画像処理で、機械学習ではあるがDeep Learningではない

Step 1

トレイをレジ
カウンターに置く



Step 3

一瞬で
レジ入力が完了
(従来の手入力も可能)



Step 2

トレイ上の
パンを撮影



Step 4

お客様にも
見えるので安心



きゅうりのAI

実家のきゅうり農家を継いだ元ソフトウェアエンジニアが自作
きゅうりの等級選別をなるべく自動で行いたい → AIによる自作開発
Webカメラ、Raspberry Pi、Tensorflowで環境構築、きゅうりを運ぶベルト
コンベアも自作
教師データ用画像2万8000枚、8000枚のテスト画像での精度は約80%
完全選別ではなく、人間のサポートとして使用すると、仕分けスピードが約
40%向上

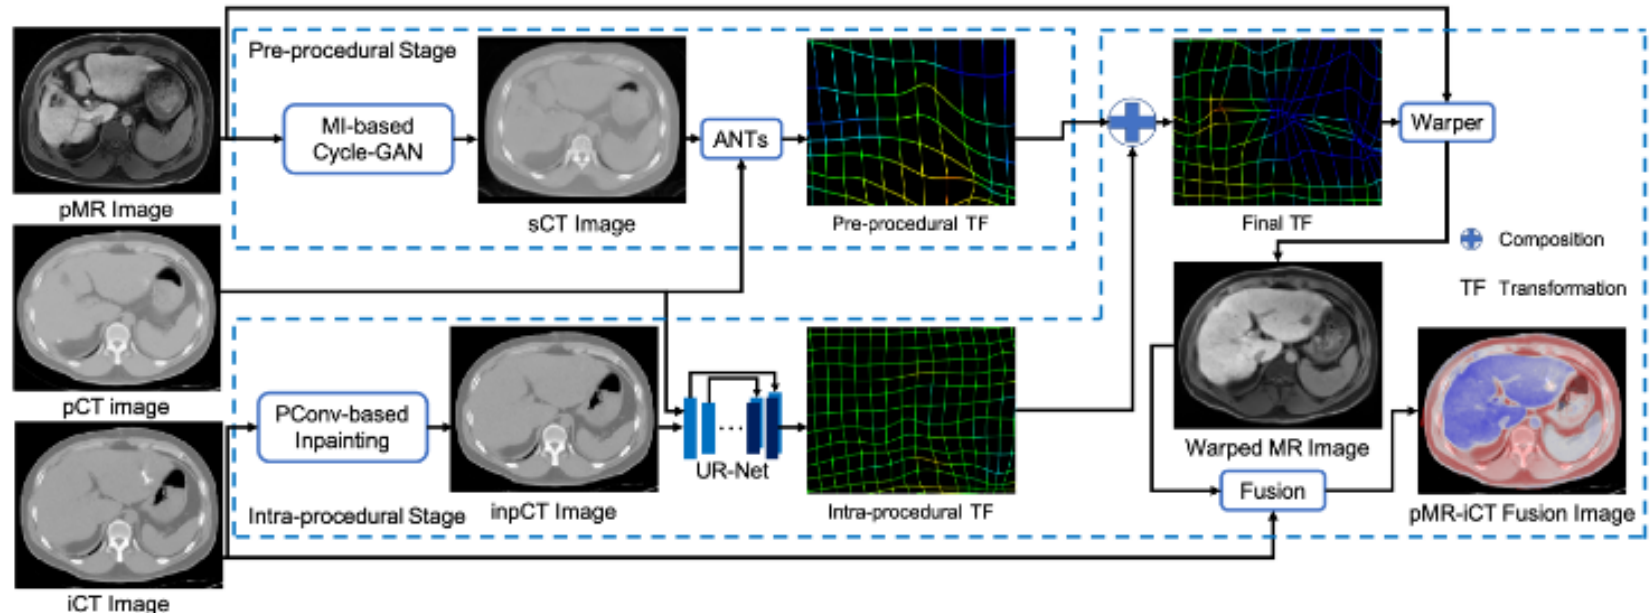
元組み込みエンジニアの農家が挑む「きゅうり選別AI」 試
作機3台、2年間の軌跡
[https://www.itmedia.co.jp/enterprise/articles/1803/12/new
s035.html](https://www.itmedia.co.jp/enterprise/articles/1803/12/news035.html)



医療診断：肝臓腫瘍候補の検出

MR/CT画像を合成した画像から、肝臓腫瘍を検出

Cycle-GANをベースにしたニューラルネットワークを構築




Wei, Dongming, et al. "Synthesis and Inpainting-Based MR-CT Registration for Image-Guided Thermal Ablation of Liver Tumors." International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, Cham, 2019.

構築したネットワーク

Layer Name	Filter Size	Number of Filter	Stride	Padding	Nonlinearity
Concat_1(Moving, Fixed)					
Conv3D_1	$3 \times 3 \times 3$	2	1	Y	LeakyReLU(0.2)
Conv3D_2	$3 \times 3 \times 3$	2	1	Y	LeakyReLU(0.2)
Conv3D_3	$3 \times 3 \times 3$	16	2	Y	LeakyReLU(0.2)
Conv3D_4	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Conv3D_5	$3 \times 3 \times 3$	32	2	Y	LeakyReLU(0.2)
Conv3D_6	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Conv3D_7	$3 \times 3 \times 3$	32	2	Y	LeakyReLU(0.2)
Conv3D_8	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Conv3D_9	$3 \times 3 \times 3$	32	2	Y	LeakyReLU(0.2)
Conv3D_10	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Conv3D_11	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Upsampling3D_1		32	2		
Concat_2(Conv3D_8)		32+32			
Conv3D_12	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Upsampling3D_2		32	2		
Concat_3(Conv3D_6)		32+32			
Conv3D_13	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Upsampling3D_3		32	2		
Concat_4(Conv3D_4)		32+32			
Conv3D_14	$3 \times 3 \times 3$	32	1	Y	LeakyReLU(0.2)
Conv3D_15	$3 \times 3 \times 3$	16	1	Y	LeakyReLU(0.2)
Upsampling3D_4		16	2		
Concat_4(Conv3D_2)		2+16			
Conv3D_16	$3 \times 3 \times 3$	6	1	Y	LeakyReLU(0.2)
Conv3D_17	$3 \times 3 \times 3$	3	1	Y	Linear

診断画像からの病気予測(1)

陽電子放出断層撮影(PET)画像の結果から、アルツハイマーを予測・分類
3層の畳み込みを含む5層ネットワークを使用
提案手法(PETNet)が最も高い予測を得ている

Method	Accuracy (2-Classes)	Accuracy (3-Classes)
 PETNet	93%	77%
PETNet (empty graph)	88%	55%
PETNet (random graph)	86%	64%
ResNet (without pre-training)	83%	58%
ResNet (with pre-training)	95%	65%
XGBoost	88%	62%
SVM	69%	57%

Guo, Jiaming, et al. "Predicting Alzheimer's Disease by Hierarchical Graph Convolution from Positron Emission Tomography Imaging." arXiv preprint arXiv:1910.00185 (2019).

診断画像からの病気予測(2)

富士フイルム 画像診断系プラットフォームREiLI

富士フイルムは新しい画像診断ワークフローを実現するために、オープンなプラットフォームを提供していきます。
このプラットフォーム上には、当社が開発するAI技術だけでなく、世界中に存在するAI技術を搭載していきます。
多種多様なAI技術を連携することで、幅広いニーズをカバーしていきます。



<http://reili.fujifilm.com/ja/>

書籍紹介：AI概論、動向

60分でわかる！機械学習&ディープラーニング超入門：機械学習研究会
技術評論社、2017 本当に超入門。コンパクトにとりあえず概要をつかむ本

人工知能は人間を超えるか ディープラーニングの先にあるもの：松尾豊、
KADOKAWA/中経出版、2015

日本でもトップレベルのAI研究者による紹介本。内容は若干古いですが、非常にわかりやすく、かつコンパクトにまとめられている

AI白書 2020：独立行政法人情報処理推進機構 AI白書編集委員会 編、
KADOKAWA、2020

国内・国外のAI動向をまとめたもの。松尾先生も委員会に加わっている

書籍紹介：事例紹介

業界別！AI活用地図：本橋 洋介，翔泳社

タイトルの通り、AIの活用事例を集めて解説したもの

2019年11月発売なので、かなり最近の事例が多い
ただし、ここで公表されている事例が本当にAIなのかどうかは不明




書籍紹介：AIに必要な数学を学ぶ

高校数学でわかるディープラーニングのしくみ：涌井貞美、ベレ出版

Deep Learningに必要な数学について、高校数学ベースで説明した良書

著者の涌井氏は、この他「Excelでわかるディープラーニング超入門」など、平易でわかりやすい関連本を多く手がけている



この講座で今後使用するライブラリ



TensorFlow

Tensorflow, Keras : 機械学習ライブラリ

Matplotlib : Python標準のプロット用ライブラリ

Numpy : リスト、行列操作用ライブラリ

Pandas: データ解析用ライブラリ

OpenCV : 画像・映像を扱うには欠かせない画像処理ライブラリ

Deep Learningではとにかくデータ構造を入れ替えたり操作したりが多いので、Numpyと可視化のためにMatplotlibが欠かせない。また、データ解析にはPandasも使用される

AIにライブラリは必要？

必須ではない

自分で組めばもちろん必要なし

ライブラリを使うと正直ブラックボックスも多いが、
様々なネットワークが簡単に組める

主流はTensorflow/KerasとPythonによる開発

最近人気があるのがPyTorchとPython

データ操作は、Pythonを使用した方が圧倒的に楽

自作本として、例えば「ニューラルネットワーク自作入門」

著：Tariq Rashid, 監訳：新納浩幸



PC上でDeep Learningを実行するなら

CPUでは演算時間が膨大になってしまうので、NVIDIA GPUの使用がほぼ必須

ただしGPUのライブラリであるCUDA, cuDNNとPython, ライブラリのTensorflowのバージョンを合わせないといけない

※動作できるバージョンが決まっている

Python ver, 3.7, Tensorflow ver.2.1.x, CUDA 10.1.418.x, cuDNN 7.6

(最新バージョンはPython 3.8, CUDA11, cuDNN 8.0)



TensorFlow



ローカルPCとほぼ同一ではないが、Google Colaboratoryでバージョン合わせに悩むことなく簡単に実行できる

GPU

巨大なデータをGPUで扱う場合、GPUのメモリ容量に注意

最新版 RTX 3080iは12G予定

現行品では RTX 2080 8G（8万円前後）など

nVIDIA GPUは複数使用も可能なので複数使用でメモリは拡張可能
データセンター向けのTESLAシリーズは16Gなど

Google Colaboratory



PythonをWebブラウザ上で実行し、画像を組み合わせて表示できる環境
Jupyter NotebookをGoogle Compute Engine上で実装したもの。完全無料
<https://colab.research.google.com/>

Googleクラウド上のGPUや、Googleが独自開発したTensorFlow用演算ハードウェアのTPUを使用して高速な演算が可能

WebブラウザからアクセスできればOK

ただし、90分&12時間ルールがある

データはGoogle Drive上に保存するか、ダウンロードする

Google ColabのGPU速度は、おおよそGTX 1060程度（2017年3万程度）

クラウドサービスのDeep Learning API

例) Amazon Rekognition

<https://aws.amazon.com/jp/rekognition/>

JavaScriptからAPIを呼び出す

有料だが、画像1000枚の判定につき1ドル、など安価

実際に使用するには、EC2, S3などAWSの周辺知識が必要