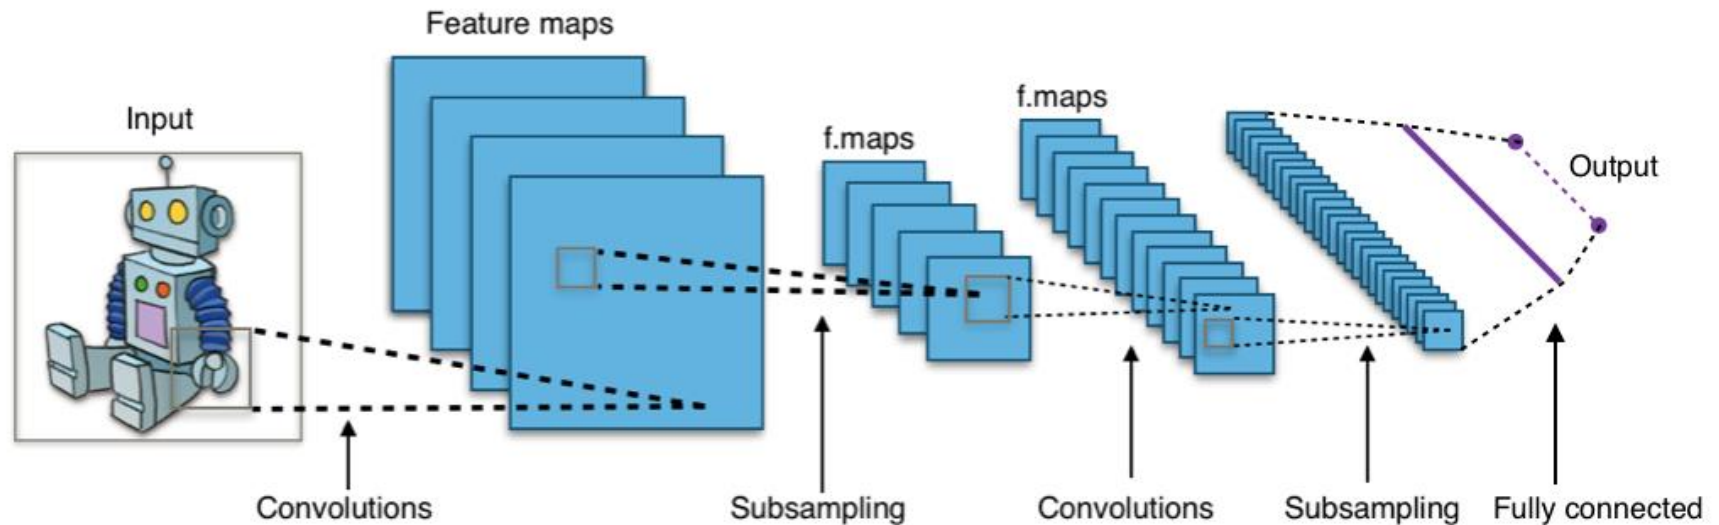


# **CNN** **(Convolutional Neural Network)** **と画像の水増し** **(Image Augmentation)**

# Convolutional Neural Network (CNN) の基礎知識

## □ CNNの一般的な構造



[https://en.wikipedia.org/wiki/Convolutional\\_neural\\_network](https://en.wikipedia.org/wiki/Convolutional_neural_network)


## □ 画像データの処理

- 畳み込み (Convolution)
- プーリング (Pooling) (Subsamplingの一種)

# 画像情報の弱点

ニューラルネットワークへの入力には1次元の形にするため、2次元の画像情報が1次元になってしまう → 画像の特徴が失われる

特徴を活かす形で入力できないといけない → 解決策の1つがCNN

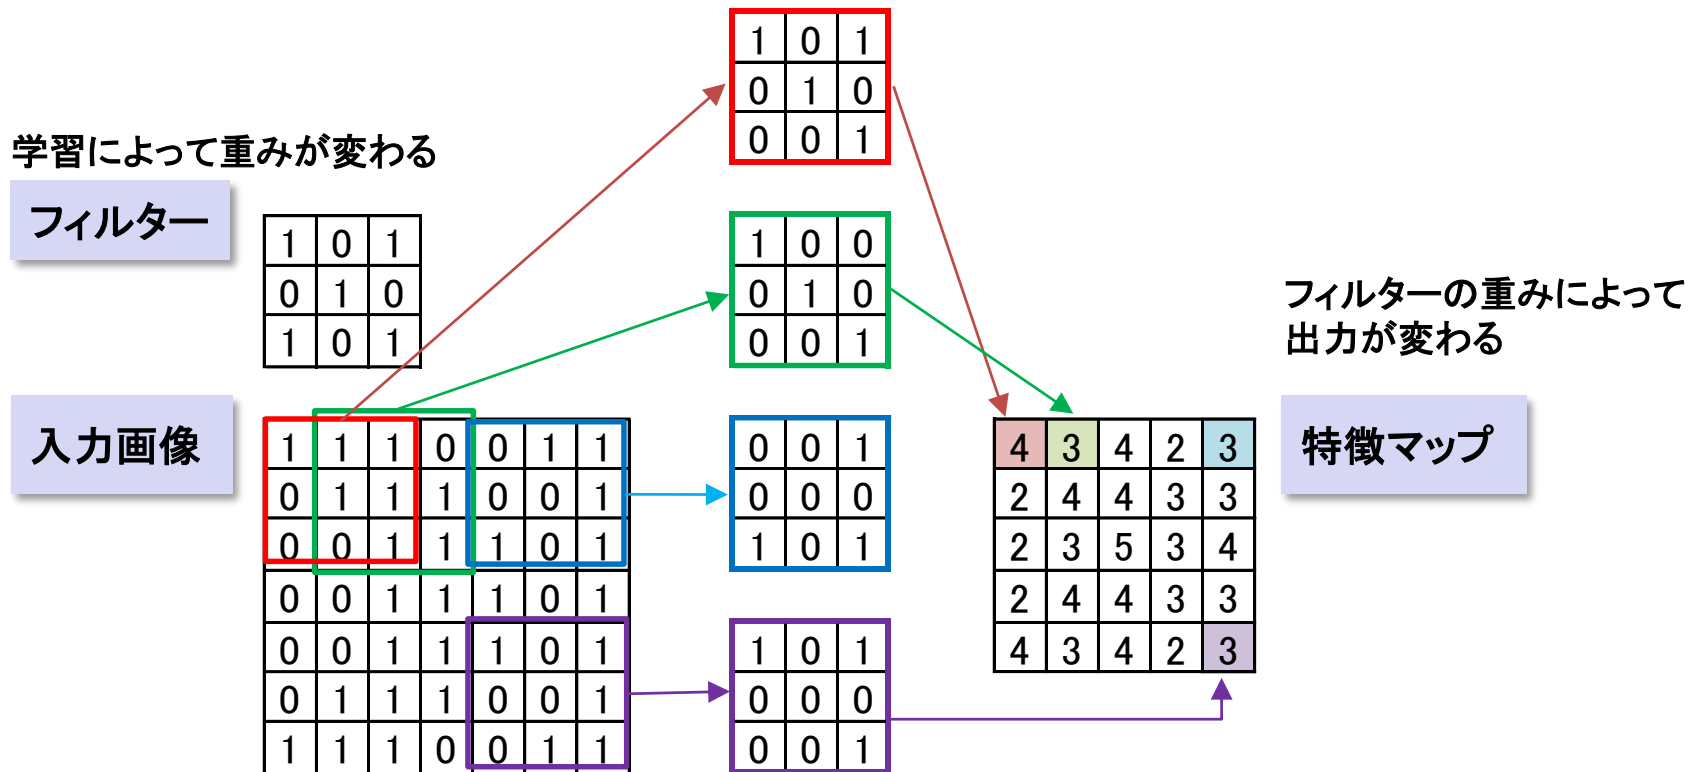


# 畳み込み (Convolution)

- 画像に小さなフィルターをかけ、その値をピクセル値として新たな画像を生成する
- 参考：  
<https://ja.wikipedia.org/wiki/%E7%95%B3%E3%81%BF%E8%BE%BC%E3%81%BF> (Wikipedia: 畳み込み)
- フィルターの重みを学習によって変化させることで、特徴を表す画像を生成する
  - 畳み込みで生成された特徴画像は特徴マップとも呼ばれる
- 後述するパディング、ストライドの大きさによって生成される画像のサイズが異なる

# 畳み込み (Convolution)

- 入力データに対してフィルターをかけることで、特徴マップを作成する
- 例：カーネルサイズ：3×3、ストライド：横1、縦1



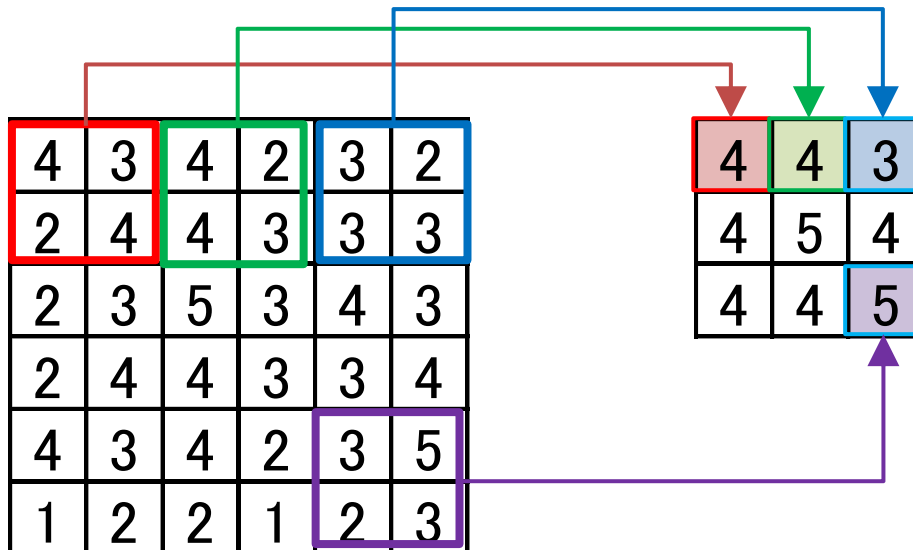
7\_1\_画像の畳み込みとプーリング.ipynbを参照

# プーリング (Pooling)

- サブサンプリングの一種
- ある領域ごとに代表値を求め、その値をピクセル値として新たに画像を生成する
- 結果として画像サイズが小さくなる（解像度が低くなる）
  - Max pooling : 最大値を代表値とする
  - Average pooling : 平均値を代表値とする
  - Sum pooling : 合計値を代表値とする
- 解像度が低くなることで、特徴の位置の多少のずれに頑健になる
- 領域の大きさによって、縮小率が変わる
  - 領域が $2 \times 2$ 、ストライド（後述）が2の場合、サイズは縦 $1/2$ 、横 $1/2$ の $1/4$ になる。

# プーリング (Pooling)


- Max poolingの例
- ウィンドウサイズ (カーネルサイズ) :  $2 \times 2$
- スライド : 横2、縦2




# パディング (Padding)

- 畳み込みを行うと、生成される画像サイズは、元の画像よりも小さくなる
- 元の画像の外側を仮に何らかの値で埋め「ふち」をつくることで、生成される画像サイズを調整する
- 0で「ふち」を埋めるゼロパディングがよく使われる

7×7




カーネルサイズ3×3  
ストライド横1、縦1で  
畳み込み



5×5

大きさ1の  
ゼロパディング  
(9×9)

0	0	0	0	0	0	0	0	0
0								0
0								0
0								0
0								0
0								0
0								0
0								0
0	0	0	0	0	0	0	0	0

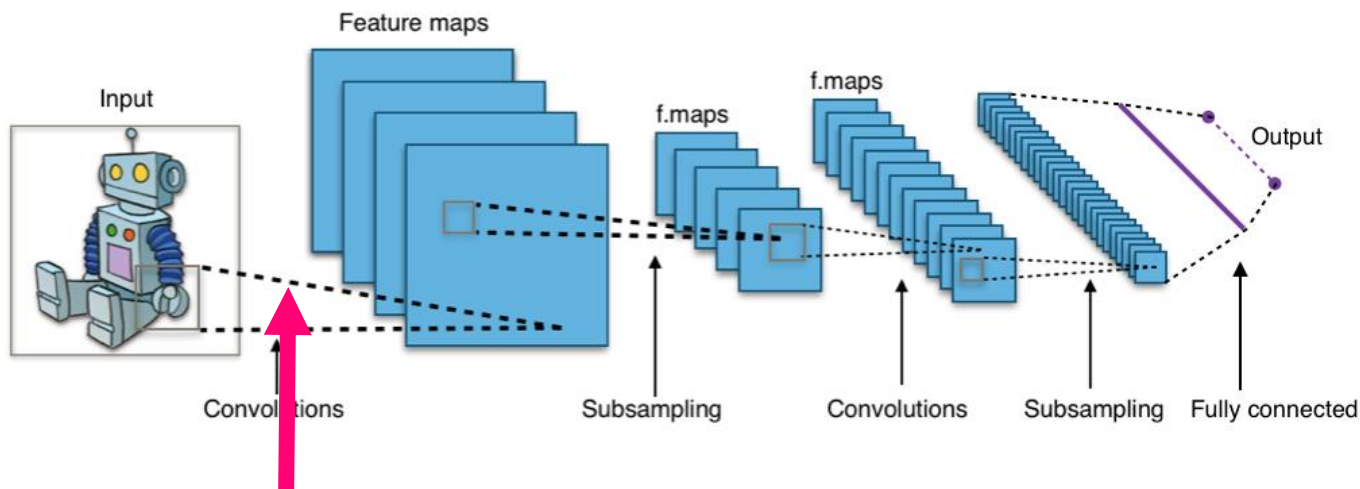


7×7



# 畳み込みの意義

- 入力画像から目的にマッチした特徴量を学習によって生成する
  - 畳み込みフィルターの重みを学習によって決定する
- 中間層が全結合ではないので、計算量が少なくなる



もし全結合にすると、入力画素数と特徴マップの画素数 × 特徴マップ数の結合が必要

[https://en.wikipedia.org/wiki/Convolutional\\_neural\\_network](https://en.wikipedia.org/wiki/Convolutional_neural_network)

# CNNとDNNの比較演習

7\_2\_MNIST分類.ipynbを参照

演習のねらい

- KerasによるCNNの基本的な実装
- DNNとCNNによる分類の精度比較

# 精度の改善

## CNNの表現力増加

- Convolution層やAffine層を深くする
- Convolution層の特徴マップ (OutMaps) 数を増やす
- Affine層のOutput数を増やす
- KernelShape (フィルターサイズ) を小さくする

## 勾配消失の回避

- 層を深くすると勾配消失により誤差が小さくても精度が悪くなる
- 活性化関数をReLUにすると勾配損失を防ぐことがある

## 過剰適合の回避

- 層を増やしすぎない
- Dropout層を入れる (ランダムにノードを無効化し表現力を落とす)

## BatchNormalization層を入れる

- 一部の入力のみの影響が大きくなりすぎることを防ぐ

# 自作データでの検証

7\_3\_自作手書き文字認識.ipynbを参照

演習のねらい

分類モデルが自作の手書き文字（準備されたデータ以外のデータ）でも分類できる汎用的な分類モデルであることを確認する

手書き数字データ

- 背景が黒で文字が白のグレースケール画像
- サイズは28×28

画像データ作成

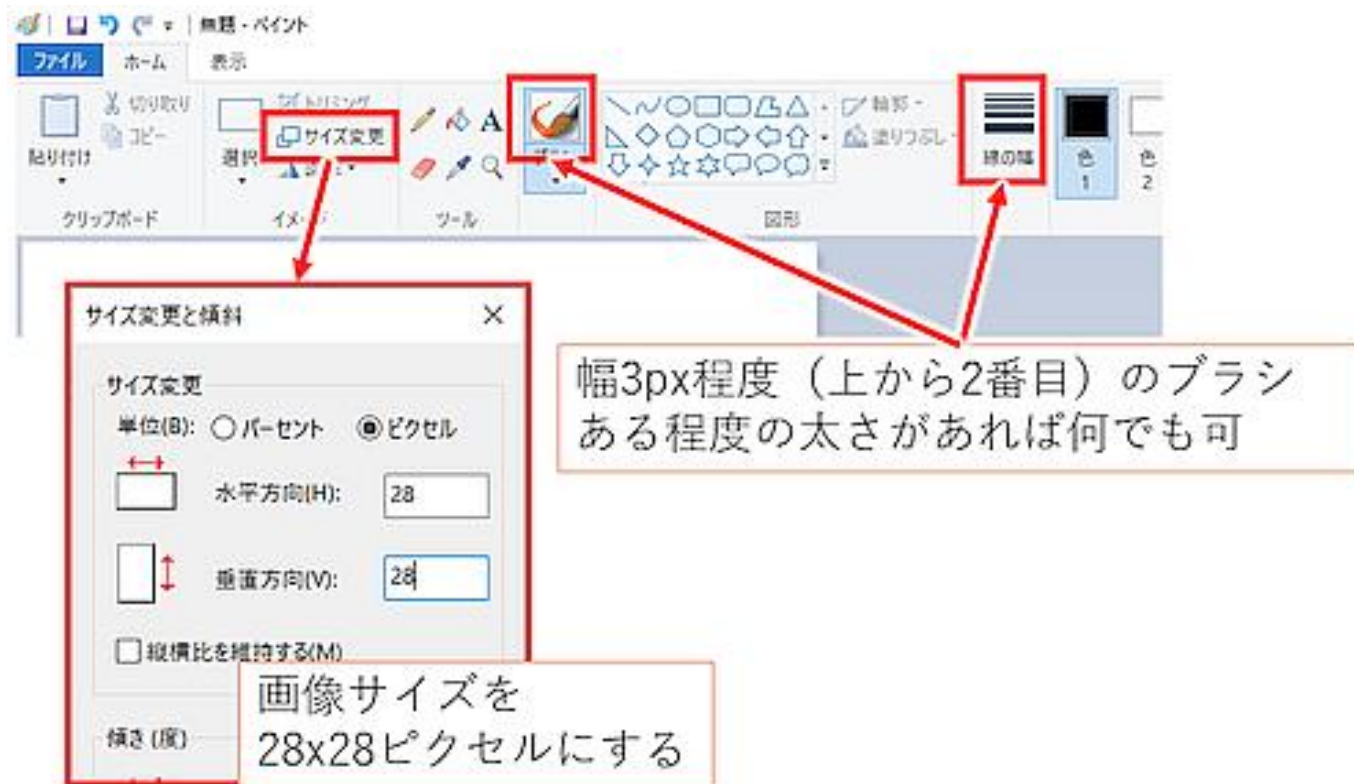
- ペイントソフトなどで文字を書く
  - ひとまず今回はペイントソフトで文字を書きます
- 紙に書いた文字をスキャナやカメラで画像化する

# 自作手書き画像の作成

ペイントを起動し、画像サイズを28x28に変更する

マウスで数字を書く（幅3px程度）

jpgとして保存したあと、GoogleDriveにアップロードする



# 画像データの水増し(Image augmentation)

学習には、画像内の対象の差異がある大量の画像データが必要  
対象の差異の種類（手書き数字の場合）

- 文字の形
- 画像内での位置
- 画像内での文字が閉める割合（サイズ）
- アスペクト比
- 回転、反転
- その他変形
- 明るさ、コントラスト、彩度

傾きやサイズ、アスペクト比などが学習データに無い場合、精度が落ちる  
画像処理で生成できるものも多い

- 一つの画像に様々な画像処理を組合せて適用し、学習データを増やす
- 予測の安定性につながる

# Kerasによる画像の水増し

keras.preprocessing.image.ImageDataGeneratorの引数は次のとおり

- rotation\_range:回転 (degree)
- width\_shift\_range : 横方向の移動 (ピクセル)
- height\_shift\_range : 縦方向の移動 (ピクセル)
- shear\_range : 歪みの角度 (degree)
- zoom\_range : スケーリングの範囲 (等倍=1.0)
- horizontal\_flip : 横方向反転 (True or False)
- vertical\_flip : 縦方向反転 (True or False)

# 画像データ水増し演習（1）

7\_4\_画像の水増し.ipynbを参照

演習のねらい

- 基本的な画像処理により水増しされる画像が、どのような画像になっているかを確認する
  - パラメータを一つずつ変更して、画像処理による加工の様子を確認する



# 画像データ水増し演習（2）

7\_5\_ASL認識モデル.ipynbを参照

演習のねらい

データ水増しにより分類精度が上がるケースを体験する  
CNNを改良して分類精度の向上を試みる

# 画像データ増し演習（2）での学習データについて

- ASL画像データは下のような画像が、画像内の手の位置が少しずつ移動したり、画像内での手の大きさが少しずつ異なる（カメラからの距離が変わる）ような画像です。1種類につき3000枚ずつあります。
- 学習データはこれらの画像から10枚ずつ抜き出したものです。つまり、ある特定の手の位置や手の大きさの10枚の画像ということになります。
- CNNによる分類では、対象の位置や大きさが異なれば、それは異なる画像となります。
- 画像処理によって様々な位置や大きさの手の画像を作ることによって、分類精度の向上が期待できます。



ブランク  
ラベル:0



A  
ラベル:1



B  
ラベル:2



C  
ラベル:3